Trefzer

DATA WAREHOUSE

HERZLICH WILLKOMMEN

Quellenangaben

Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. Wiley. Dieses Buch ist ein Standardwerk in der Data-Warehouse-Industrie und bietet eine umfassende Einführung in das Thema.
Inmon, W. H. (2005). Building the Data Warehouse (4th ed.). Wiley. Dieses Buch bietet eine andere Perspektive auf Data Warehousing und erklärt die Konzepte von Bill Inmon, einem Pionier in diesem Bereich.
Larissa T. Moss, Shaku Atre (2010). Data Warehousing in the Age of Big Data. Morgan Kaufmann. Dieses Buch erweitert das Konzept des Data Warehousing auf die Verarbeitung großer Datenmengen und Big Data.
Microsoft Azure. Wenn Sie sich für Cloud-basierte Data-Warehouse-Lösungen interessieren, bietet Microsoft Azure ein umfassendes Angebot an Ressourcen und Tutorials.

Gute Links für Beispieldatenbanken: AdventureWorks sample databases - SQL Server | Microsoft Learn

Trefzer

Welche Informationen erhalte ich hier

- Begrifflichkeiten
- Informationen
- Data Ware House Funktionen
- ETL- Begrifflichkeiten
- Staging Area & Arbeitsschritte
- Data Cube
- Datenanalyse
- Slicing & Dicing
- Data Warehous Bus
- Tabellen Strukturen (star & snowflake)

Trefzer

Begriff Data Ware House

- Ein Data Warehouse ist ein spezieller Typ von Datenbank, der entwickelt wurde, um große Mengen von Daten aus verschiedenen Quellen zu sammeln, zu speichern und zu analysieren. **(Zentrales Datenbanksystem)**

- Es dient dazu, umfassende Einblicke in Unternehmensdaten zu gewinnen und bessere Geschäftsentscheidungen zu treffen.

Hier ist eine einfache Erklärung für Anfänger, wie ein Data Warehouse funktioniert:

Trefzer

Daten sammeln:

Das Data Warehouse sammelt Daten aus unterschiedlichen Quellen

- darunter interne Systeme,
- externe Partner,
- soziale Medien,
- Azure,
- IoT-Geräte und mehr.

Diese Daten können strukturiert (z.B. Tabellen) oder unstrukturiert (z.B. Text) sein.

Trefzer

Datenbereinigung und -transformation:

Die gesammelten Daten sind oft inkonsistent und müssen bereinigt und in einheitliche Formate umgewandelt werden.

Dieser Schritt wird als ETL (Extrahieren, Transformieren, Laden) bezeichnet.

SQL DATENBANKEN
DATA WARE HOUSE

Trefzer

Daten speichern:

Die bereinigten Daten werden in einer speziellen Datenbankstruktur im Data Warehouse gespeichert. Diese Struktur ermöglicht effiziente Abfragen und Analysen.

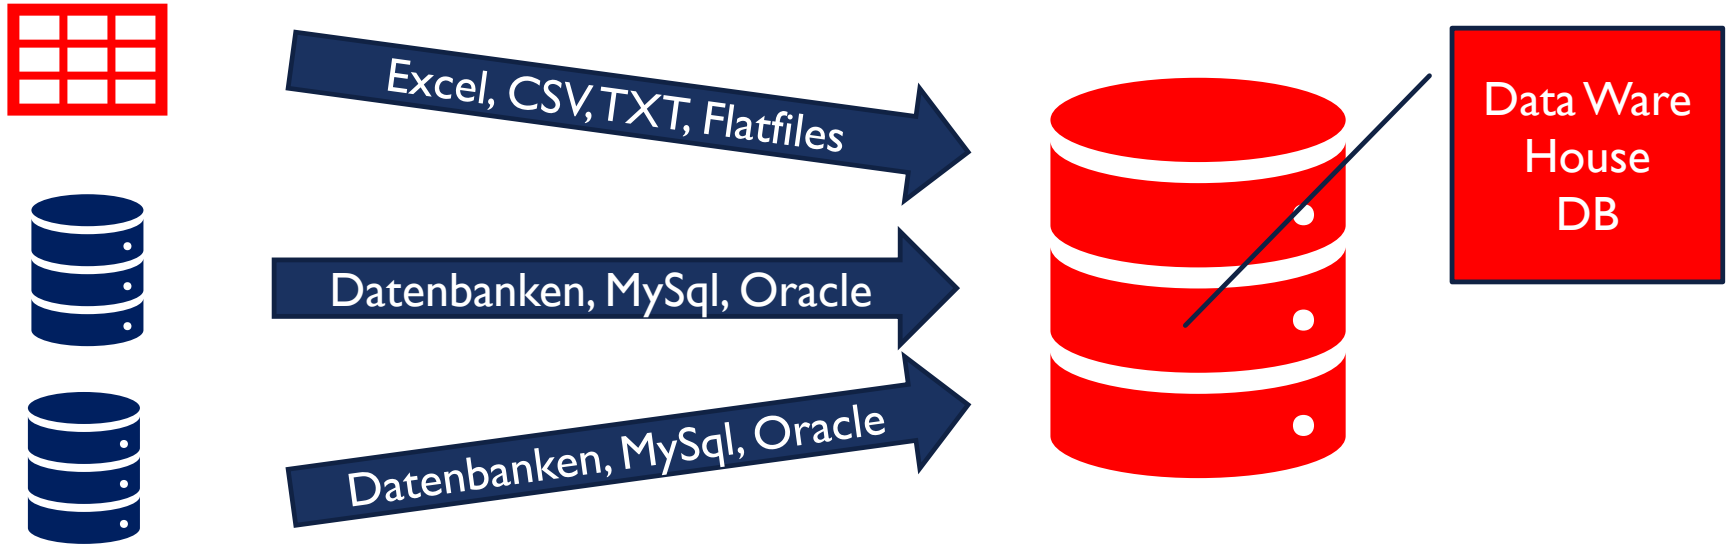

SQL DATENBANKEN
DATA WARE HOUSE

Trefzer

Staging Area (Aufbereitung in ein relationales DB System)

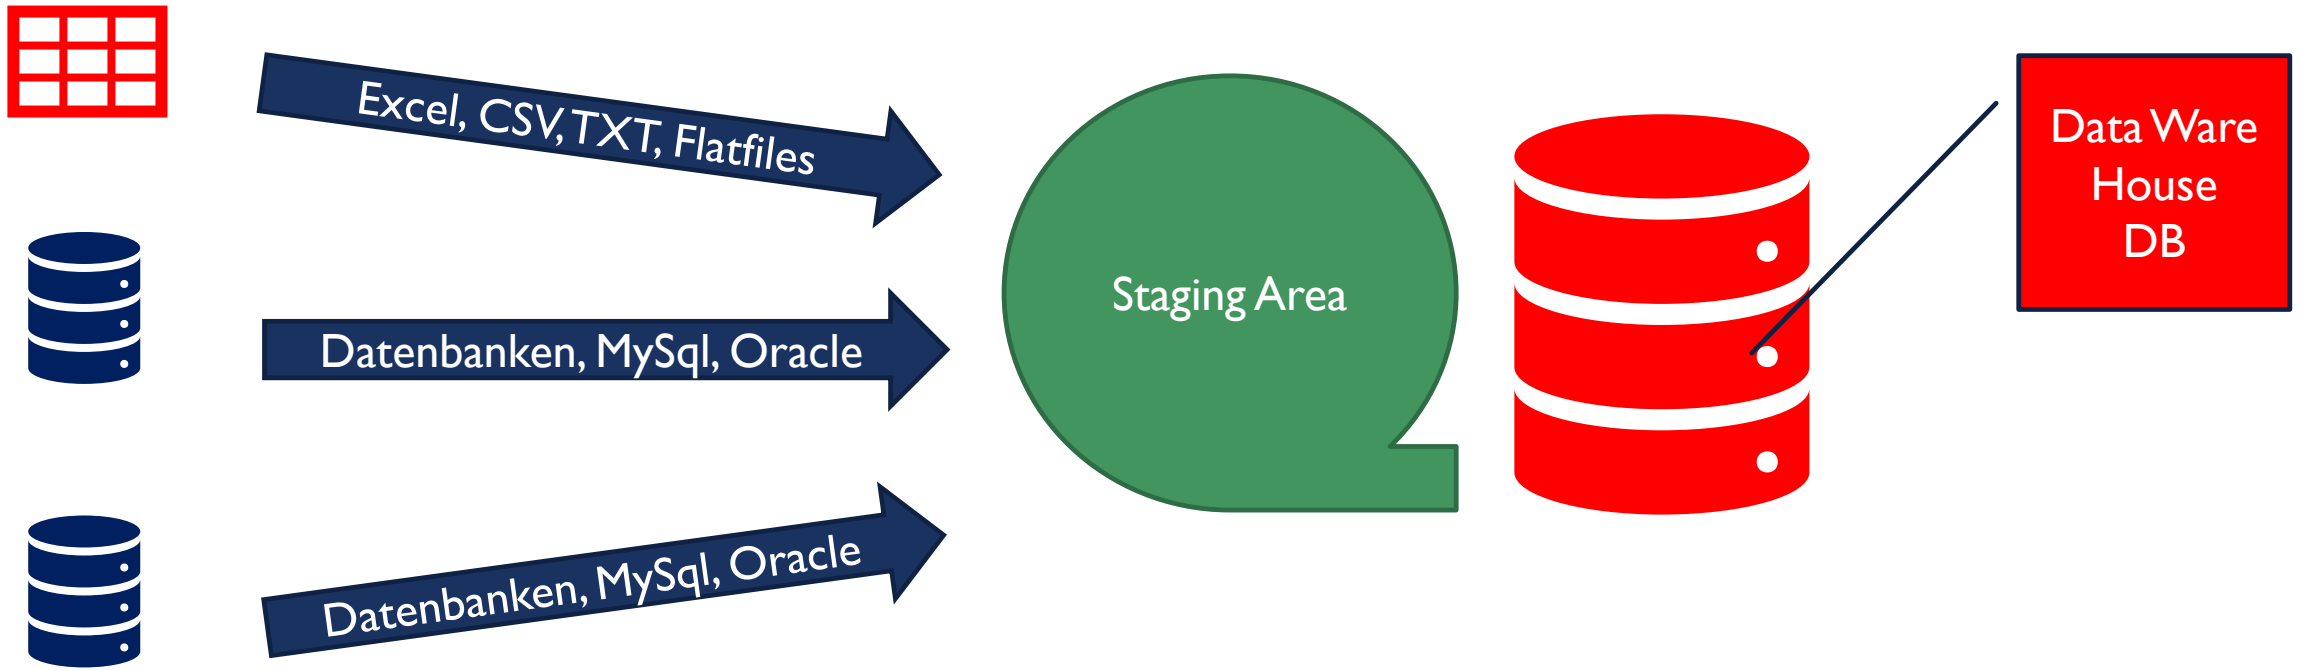

Trefzer

Was ist eine Staging Area?

Eine Staging Area ist ein Zwischenspeicher, in dem Daten vorübergehend gespeichert und aufbereitet werden, bevor sie in eine Datenbank oder ein Data Warehouse geladen werden.

Sie dient dazu, die Qualität und Integrität der Daten sicherzustellen und sie für weitere Verarbeitungsschritte vorzubereiten.

Beispiel:
Angenommen, Sie sammeln Verkaufsdaten von verschiedenen Filialen. Bevor Sie diese Daten in Ihr Data Warehouse laden, könnten Sie sie in einer Staging Area vorbereiten. Sie würden fehlende Werte ergänzen, Datumsformate standardisieren und sicherstellen, dass alle Daten in einem einheitlichen Format vorliegen. Erst dann würden Sie die bereinigten Daten in Ihr Data Warehouse übertragen.

Arbeitsschritte innerhalb der Staging Area

- **Datenbereinigung:** Daten aus verschiedenen Quellen können inkonsistent sein. In der Staging Area können Daten bereinigt werden, um Fehler zu beheben, fehlende Werte werden ergänzt und Datentypen werdne angepasst.
- ***Datenintegration*:** Wenn Sie Daten aus verschiedenen Quellen zusammenführen möchten, kann die Staging Area als Zwischenschritt verwendet werden, um Daten zu harmonisieren und miteinander zu verknüpfen.
- ***Leistungssteigerung*:** Daten können in der Staging Area optimiert werden, um die Leistung bei der Übertragung in die Datenbank zu verbessern.

Trefzer

Arbeitsschritte innerhalb der Staging Area

- ***Fehlererkennung*:** In der Staging Area können Daten auf Unstimmigkeiten und Fehler überprüft werden, bevor sie in die Hauptdatenbank geladen werden, um die Datenqualität sicherzustellen.
- ***Historisierung*:** In einigen Szenarien werden historische Daten in der Staging Area aufbewahrt, um Änderungen und Entwicklungen im Zeitverlauf zu erfassen, bevor sie in die Hauptdatenbank geladen werden.

Trefzer

Daten in das DWH speichern

- Die bereinigten Daten werden in einer speziellen Datenbankstruktur im Data Warehouse gespeichert.
- Diese Struktur ermöglicht effiziente Abfragen und Analysen.

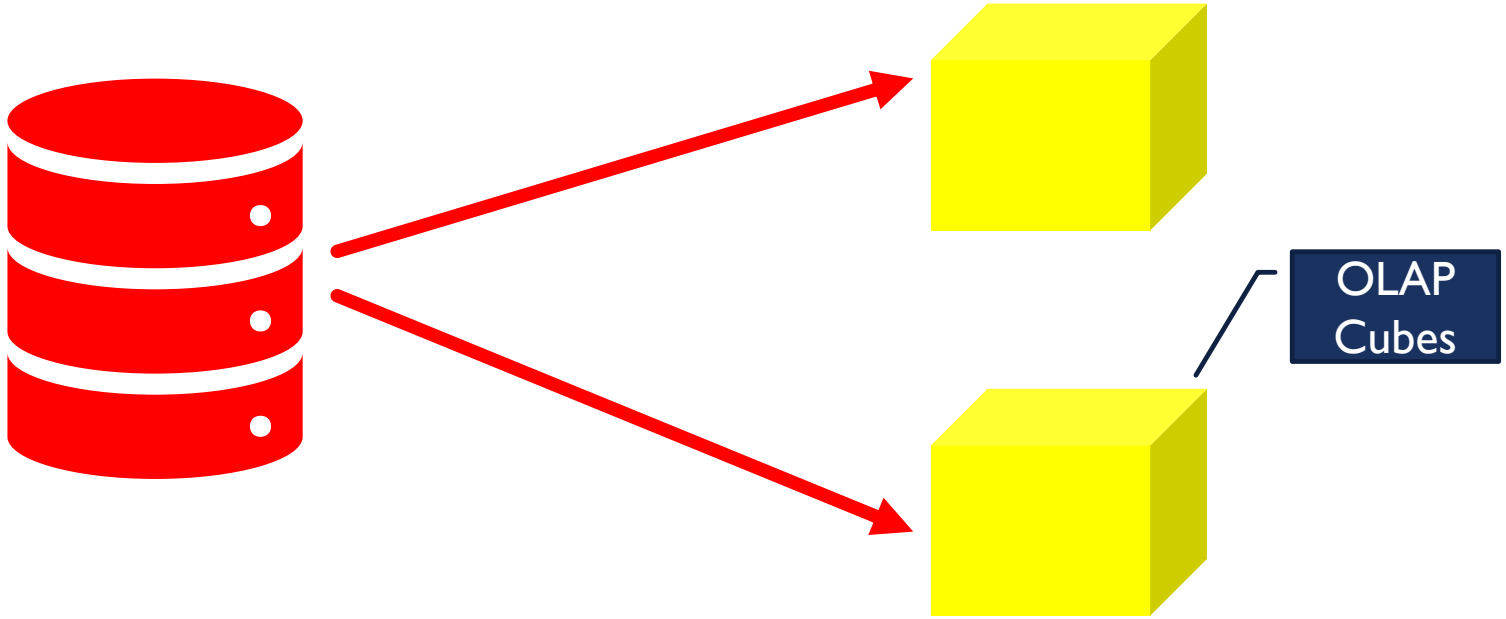

Trefzer

Daten in das DWH speichern

- **Abfragen und Analyse**: Nutzer, wie Geschäftsanalysten und Führungskräfte, können Abfragen an das Data Warehouse senden, um Informationen zu erhalten. Dies können einfache Abfragen bis hin zu komplexen Datenanalysen sein.
- **Berichterstellung und Visualisierung**: Die Ergebnisse der Abfragen werden oft in Berichten und Visualisierungen präsentiert, um die Daten verständlicher zu machen. Tools wie Tableau, Power BI oder Excel können hierbei verwendet werden.
- **Geschäftsentscheidungen treffen**: Basierend auf den gewonnenen Erkenntnissen können Unternehmen bessere Entscheidungen treffen. Dies können strategische Entscheidungen, Produktverbesserungen oder Marketingkampagnen sein.

SQL DATENBANKEN
DATA WARE HOUSE

Trefzer

Data-Cube:

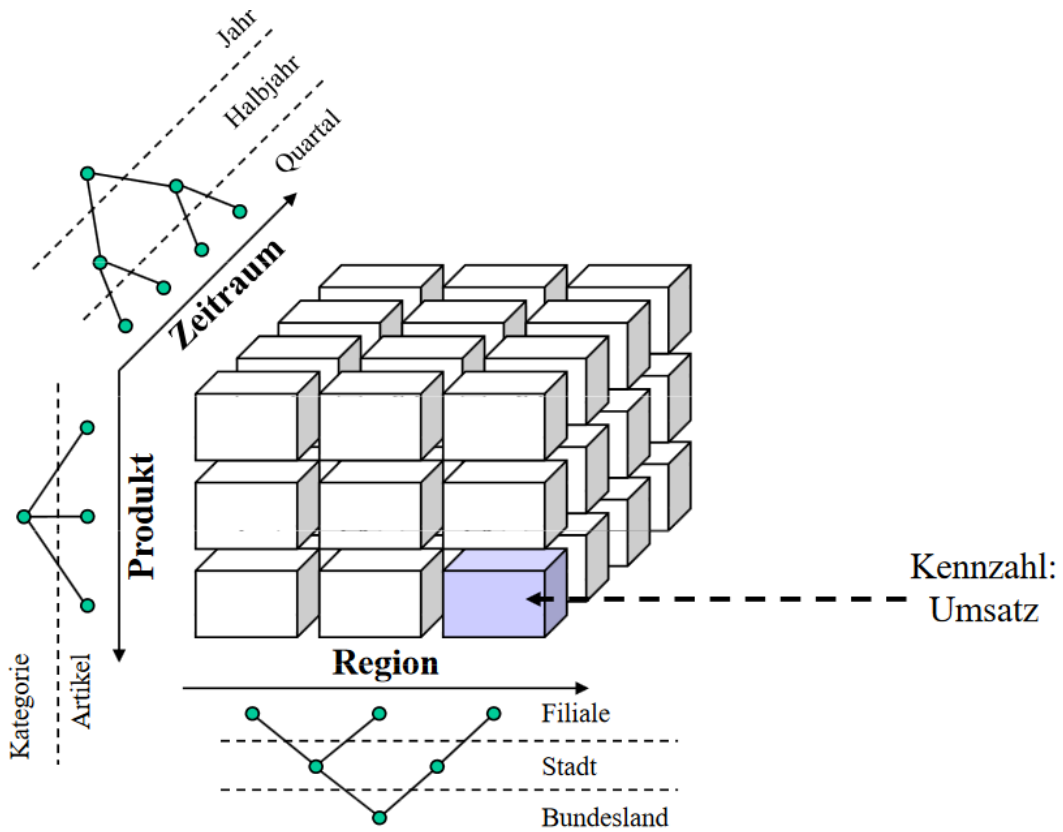

Standardoperationen zur Datenanalyse

Pivotisierung / Rotation

- Drehen des Data-Cubes durch Vertauschen der Dimensionen
- Datenanalyse aus verschiedenen Perspektiven

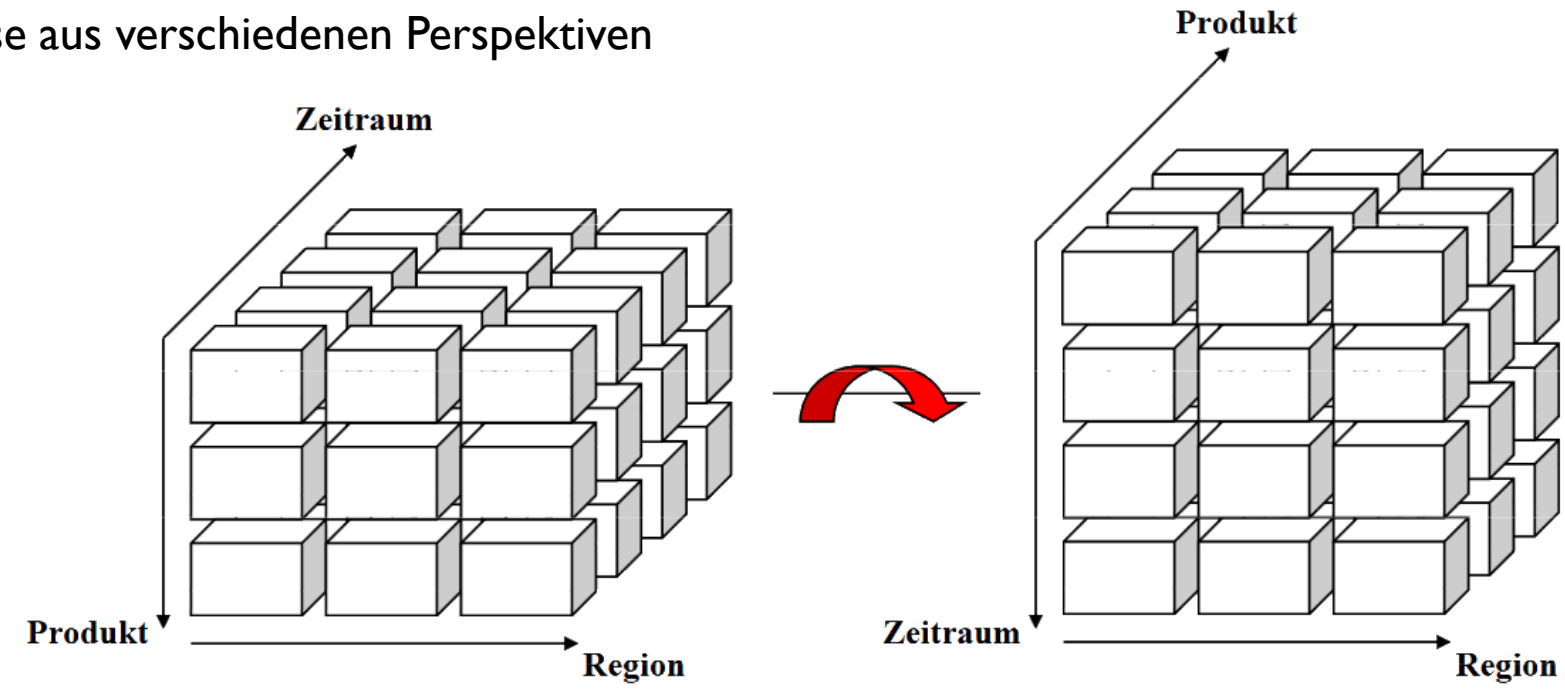

Standardoperationen zur Datenanalyse

Drill-Down & Roll-Up

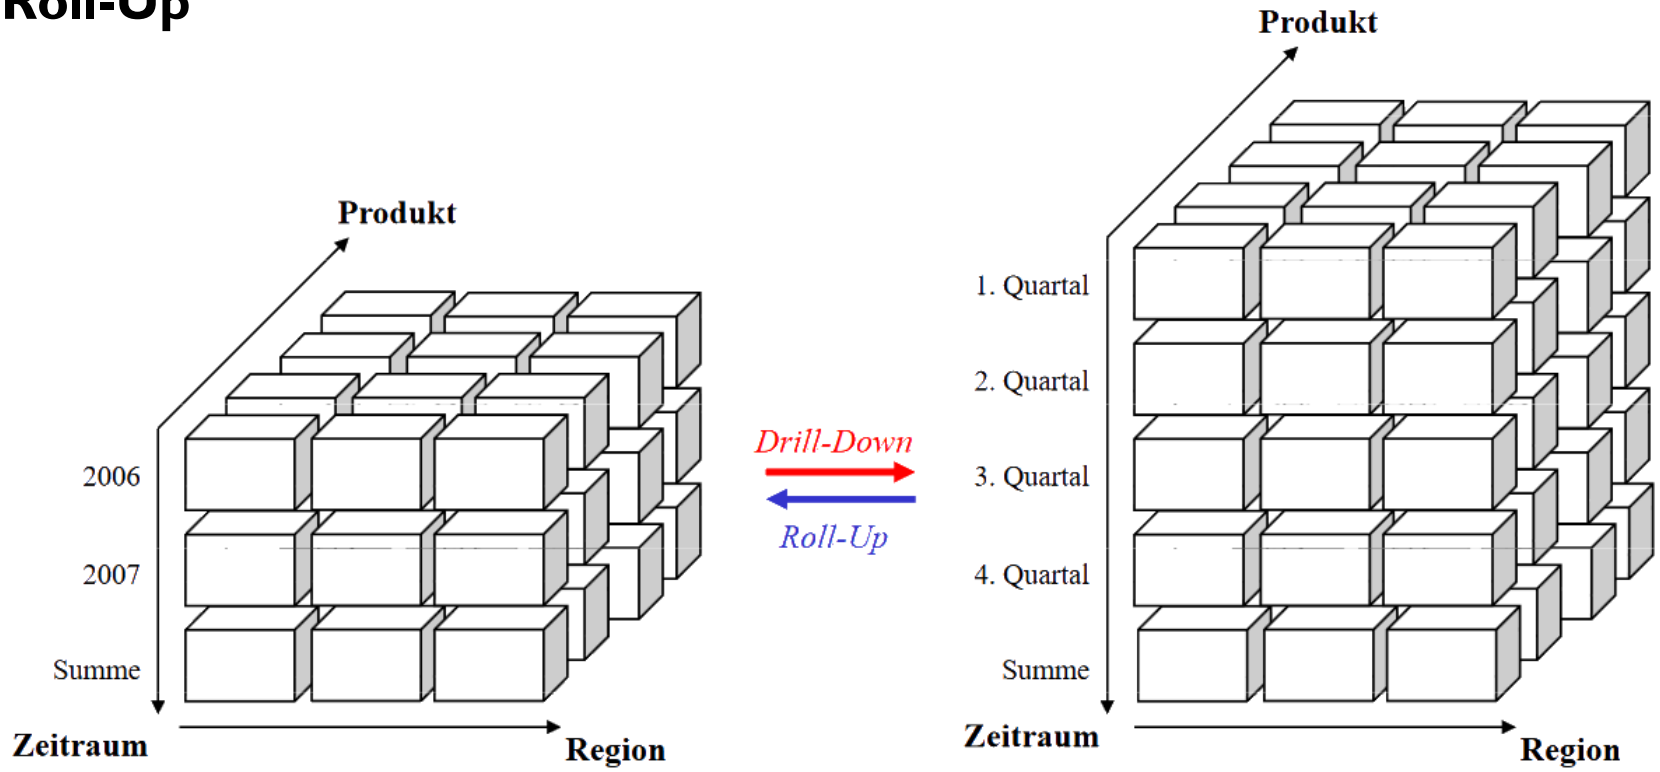

Standardoperationen zur Datenanalyse

Dicing:

- Dicing ist ein Prozess, bei dem Daten in einem Data Warehouse in kleinere Würfel oder Teilmengen aufgeteilt werden.
- Dies geschieht, indem Daten nach bestimmten Dimensionen oder Kategorien ausgewählt werden.
- Diese Dimensionen können Zeit, Ort, Produktkategorie, Kunden oder andere relevante Attribute sein, je nach den Anforderungen der Analyse.

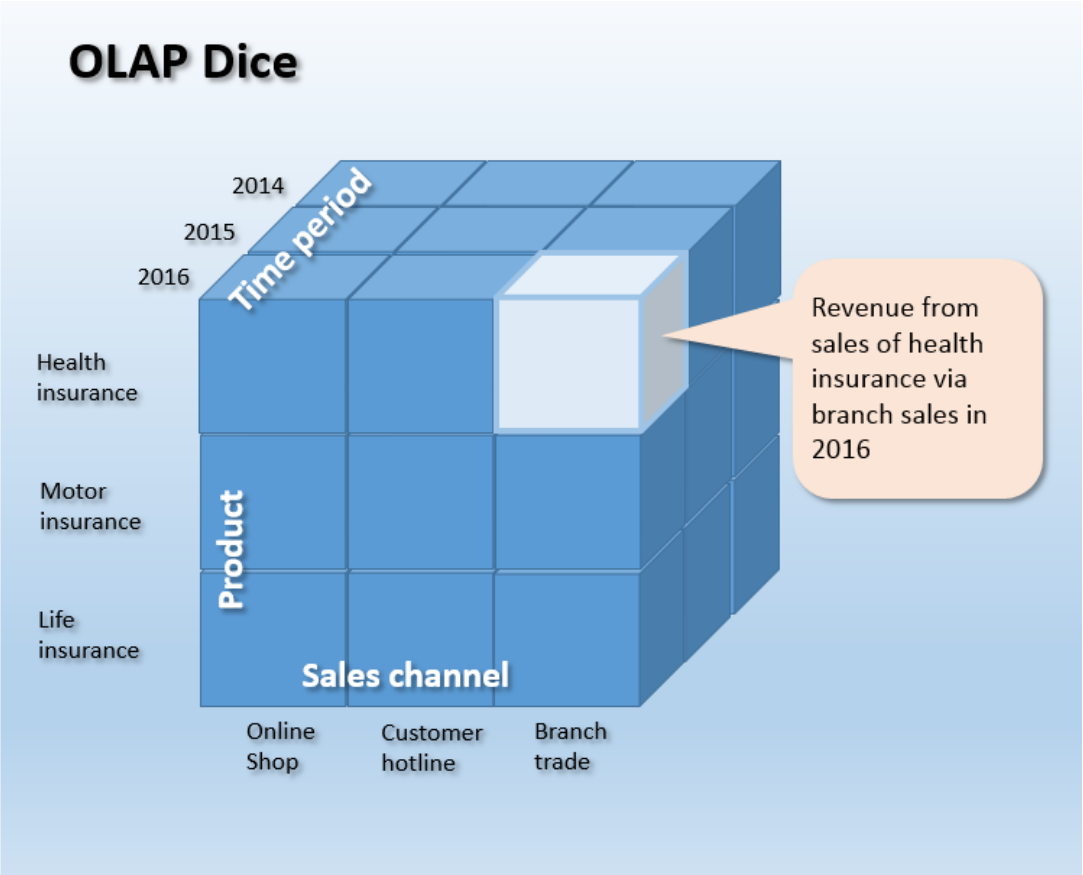

Standardoperationen zur Datenanalyse

Slicing:

- Das Slicing bezieht sich auf den Prozess, bei dem Daten in einem Data Warehouse basierend auf einer einzelnen Dimension gefiltert oder aufgeteilt werden.
- Diese Dimension kann beispielsweise die Zeit, der Ort, die Produktkategorie, der Kunde oder ein anderes relevantes Attribut sein.
- Das Ziel ist es, nur die Daten zu betrachten, die in Bezug auf diese Dimension von Interesse sind.

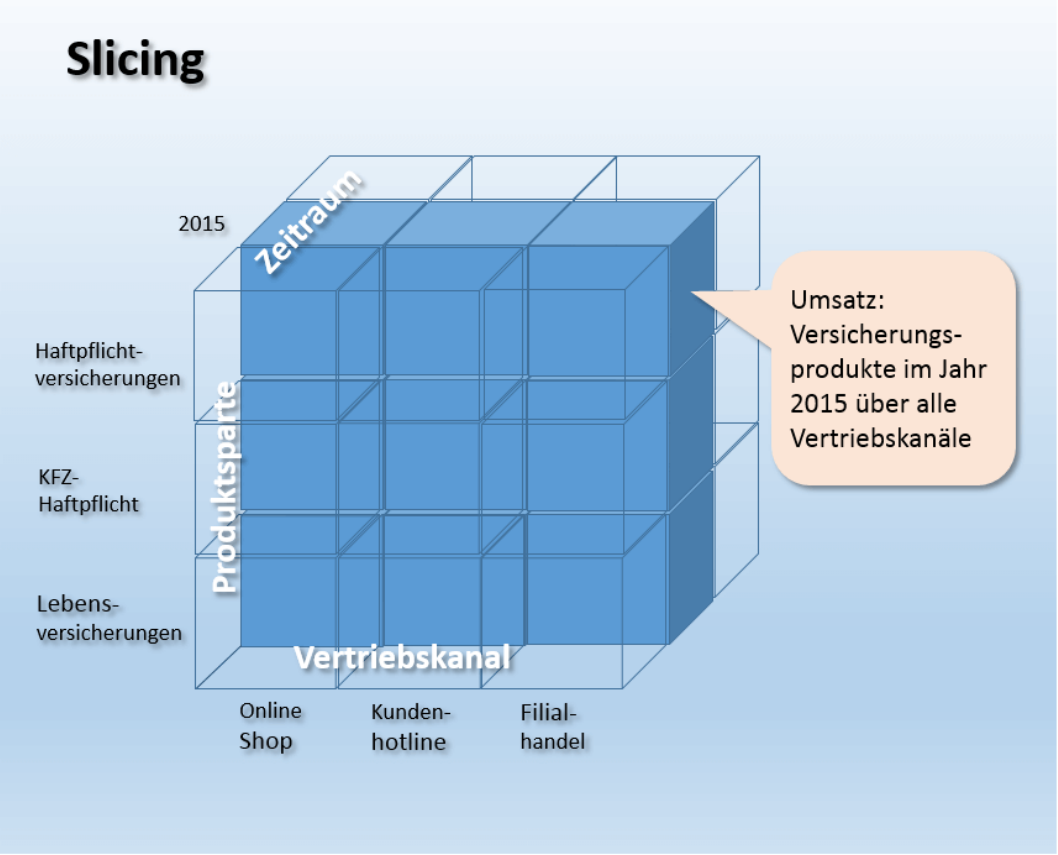

SQL DATENBANKEN
DATA WARE HOUSE

Trefzer

Bekanntester Theoretiker im DWH Umfeld - Nach Ralph Kimball

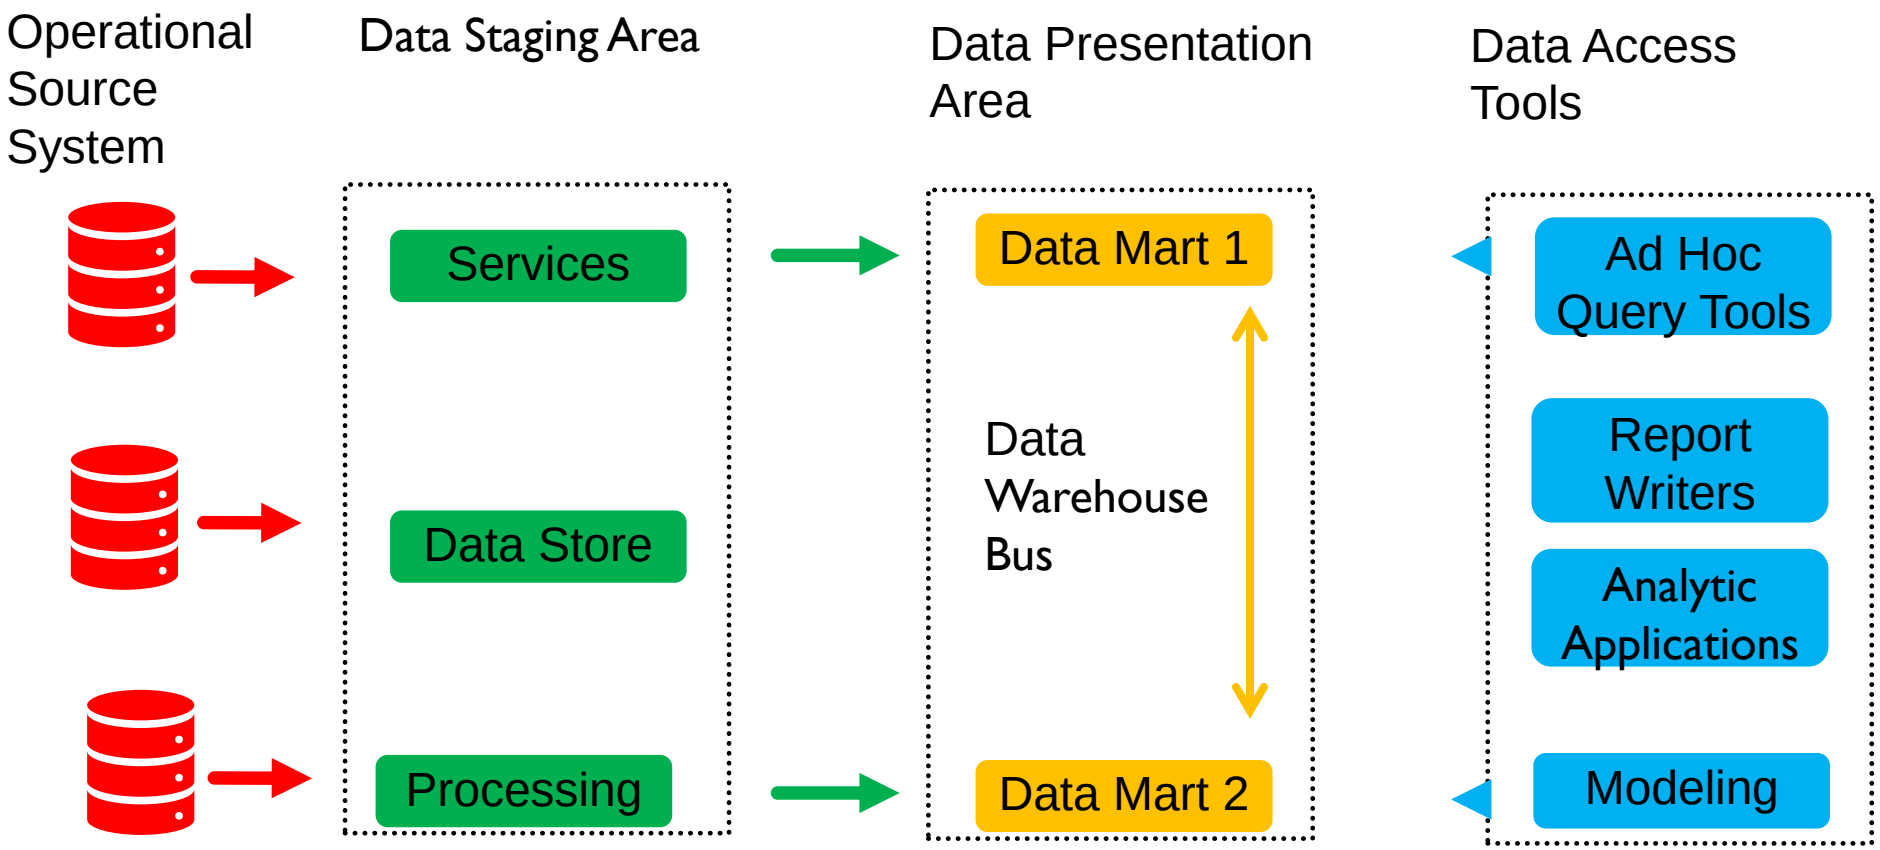

Trefzer

Data Warehouse Bus

Verbindung zwischen Faktentabellen welche die selben Dimensionstabellen verwenden können, z. B.

- Einkauf
- Verkauf

Innerhalb einer DWH Bus Matrix erkennt man welche Daten wer liefern kann

- Welche Kennzahlen kann ich mit welchen Dimensionen kombinieren

	Date	Product	Store	Promotion	Warehouse	Vendor	Shipper
Store Sales	X	X	X	X			
Store Inventory	X	X	X				
Purchase Orders	X	X			X	X	X

SQL DATENBANKEN
DATA WARE HOUSE

Trefzer

Sternform (star)

Dimensionstabellen

Faktentabelle

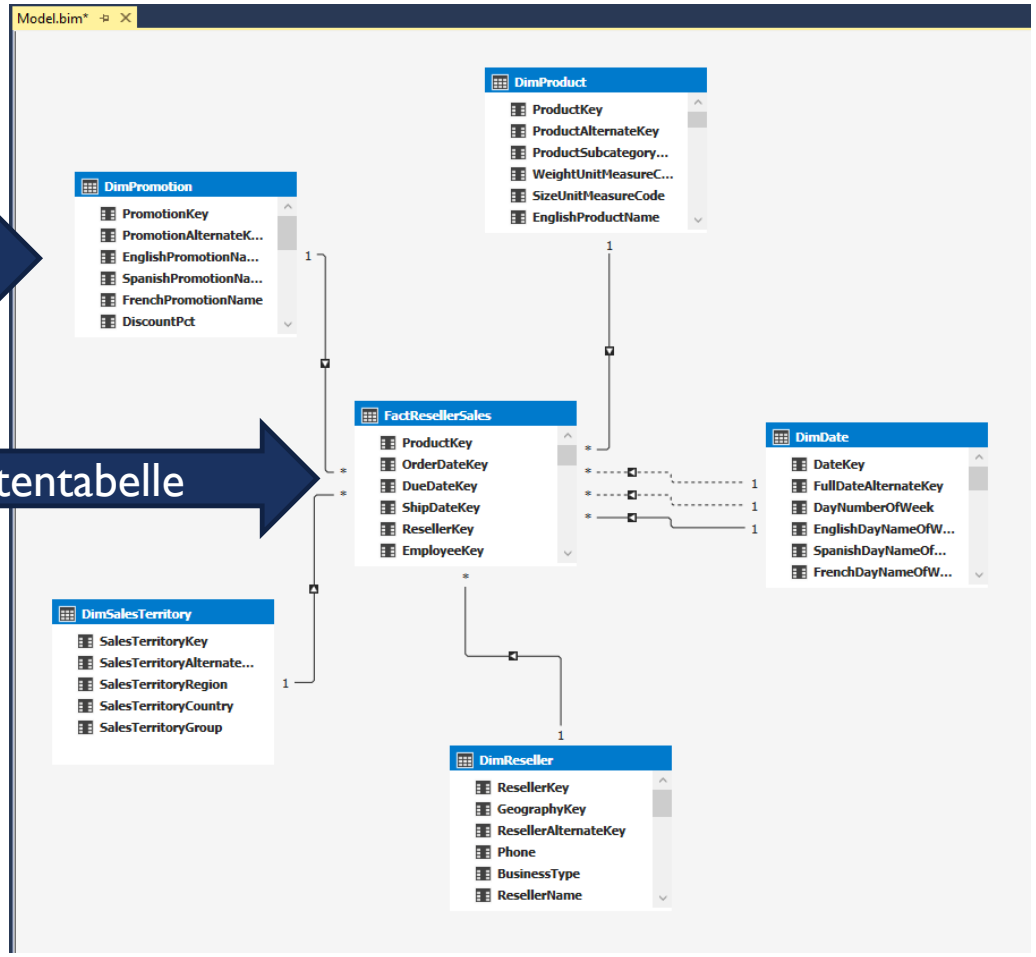

SQL DATENBANKEN
DATA WARE HOUSE

Trefzer

Schneeflocke (Snowflake)

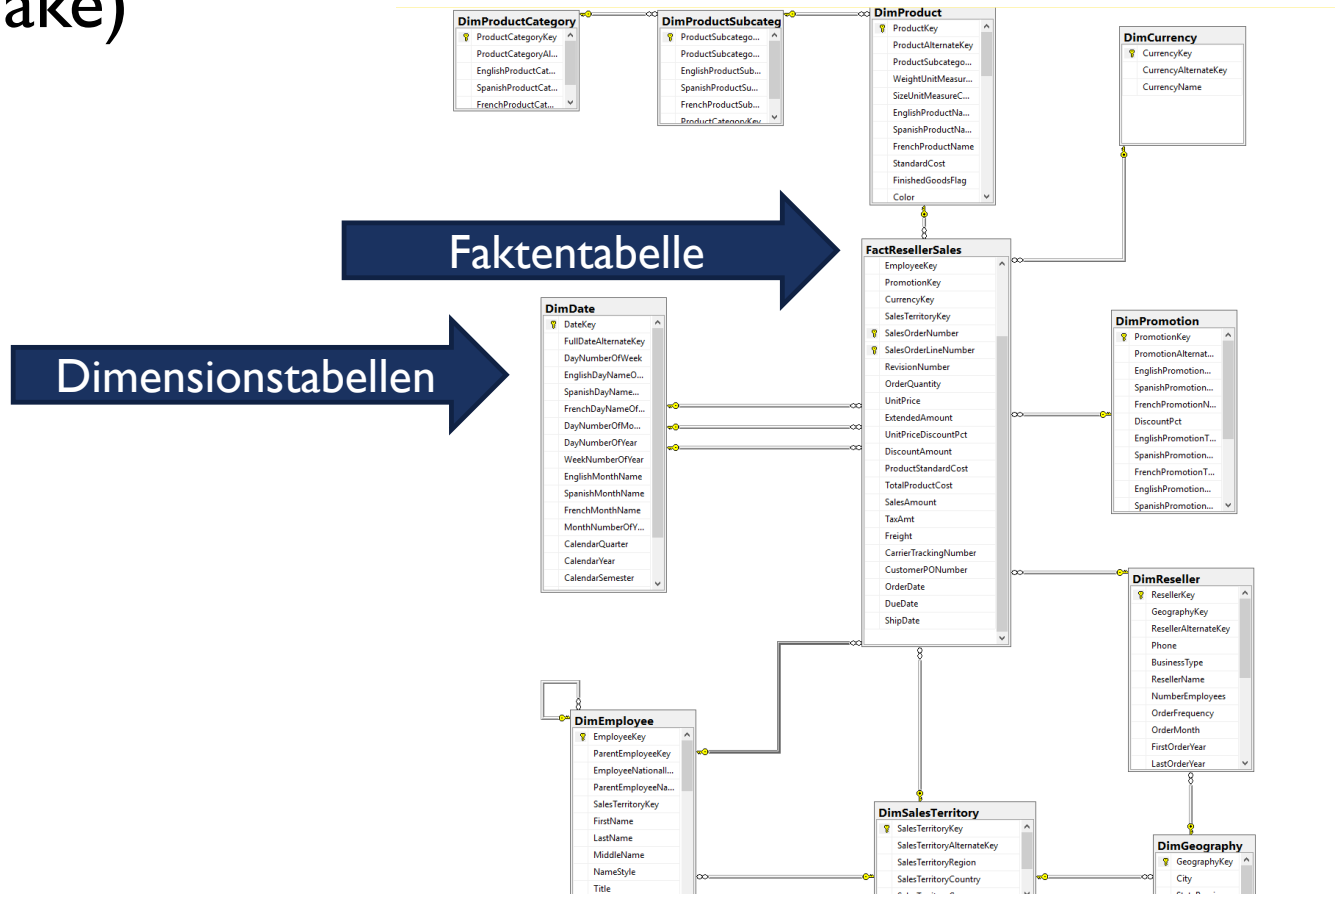

VIELEN DANK

MARKUS TREFZER